

Multilayer Perceptron e Precipitação: Análise de Desempenho


Renan Oliveira Nunes



Multilayer Perceptron?

- O MLP aprende padrões históricos (**Lags**) para projetar estados futuros (**Leads**) através de aproximação de funções não-lineares.

Rede neural feedforward totalmente conectada.



Exemplo:





Imagem típica de uma busca por redes neurais


MLP - Multilayer Perceptron



MLP - Multilayer Perceptron

- Funções de ativação
- Funções custo
- Número de neurônios: k

$$\vec{Z}_{k \times 1} = \mathbb{W}_{k \times j} \cdot \vec{X}_{j \times 1} + \vec{b}_{k \times 1}$$



MLP - Multilayer Perceptron

Pré-processamento

Normalização Z-score:

Garante que variáveis com escalas diferentes tenham o mesmo peso no treinamento.

$$z = \frac{x - \mu}{\sigma}$$

$\mu \rightarrow$ Média

$\sigma \rightarrow$ Desvio padrão

Diferentes Funções de ativação

$$\sigma(x) = \frac{1}{1 + e^{-x}}$$

$$\text{ReLU}(x) = \max(0, x)$$

$$\text{LeakyReLU}(x) = \begin{cases} x & \text{if } x > 0 \\ \alpha x & \text{otherwise} \end{cases}$$

$$\text{softmax}(x_i) = \frac{e^{x_i}}{\sum_j e^{x_j}}$$

Diferentes funções custo e métricas de avaliação

Mean Absolute Error

$$\text{MAE} = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i|$$

Mean Squared Error


$$\text{MSE} = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

Nash-Sutcliffe Efficiency

$$\text{NSE} = 1 - \frac{\sum_{i=1}^n (O_i - P_i)^2}{\sum_{i=1}^n (O_i - \bar{O})^2}$$

Overfitting  Generalização

Dados de reanalise do ERA5




- Dados de precipitação do ERA5
- Resolution: $0.25^\circ \times 0.25^\circ$
- 1940 - Atual

Resultados para Porto Alegre

- $30^\circ 01' 58''$ Sul (latitude)
- $51^\circ 13' 48''$ Oeste (longitude)

Dados de reanálise do ERA5



Dados de precipitação do ERA5

Resolution: $0.25^\circ \times 0.25^\circ$


1940 - Atual

Resultados para Porto Alegre

➤ $30^\circ 01' 58''$ Sul (latitude)

➤ $51^\circ 13' 48''$ Oeste (longitude)

Dados de reanalise do ERA5




Dados de precipitação do ERA5

Resolution: $0.25^\circ \times 0.25^\circ$

10.10 - Atual


para Porto Alegre
01' 58" Sul (latitude)
3' 48" Oeste (longitude)

Previsão de Temperatura Máxima



Erro Médio Absoluto no Teste: 1.77°C

Previsão de Temperatura Máxima



- Boa performance na predição de temperatura e sazonalidade.
- Erros estáveis mesmo em Leads de 10 dias.
- Lag de 5 dias apresentou o melhor equilíbrio entre custo computacional e precisão para o dia seguinte.

Exemplo extra: Previsão do nível do Rio Paraibuna - MG

Earth Science Informatics (2023) 16:4313–4326
<https://doi.org/10.1007/s12145-023-01159-5>

METHODOLOGY

Use of neural network as a support tool in water level forecasting and issuing flash floods early warnings to three small Brazilian urban watersheds


Glauston R. T. de Lima¹ · Rochane de Oliveira Caran¹ · Luiz Ferreira de Aguiar Filho²

Received: 26 July 2023 / Accepted: 10 November 2023 / Published online: 22 November 2023
© The Author(s), under exclusive licence to Springer-Verlag GmbH Germany, part of Springer Nature 2023




Uso de variáveis de precipitação e nível do rio das últimas 3 h para projetar o cenário das 3 h seguintes.

Desempenho otimizado através de dados de alta frequência (transmissão de 10 min a 1h) provenientes da rede do Cemaden.




Exemplo extra: Previsão do nível do Rio Paraibuna - MG



O MLP tem capacidade de antecipação para a emissão de alertas precoces de cheias repentinas (*flash floods*).

Previsão de precipitação

Precipitação para o período entre janeiro e maio de 1998.



1 Camada com 32 neurônios

Lag = 3 dias

Inputs:


- psl, 10mU, 10mV
- tasmax, Cape
- tcw, Pr

Hidden layers=[31]

Activation = Sigmoid

Previsão de precipitação

Lag=3




Hidden layers=[256, 128, 64]

Activation = ReLU


Previsão de precipitação

Lag=5

Precipitation Forecast vs. Data



Forecast Magnitude Bias





Hidden layers=[256, 128, 64]

Activation = ReLU

Previsão de precipitação

Lag=7




Hidden layers=[256, 128, 64]

Activation = ReLU

Previsão de precipitação

Lag=15




Hidden layers=[256, 128, 64]

Activation = ReLU


Previsão de precipitação

Versão espacial: Lag=3




Hidden layers=[256, 128, 64]

Activation = ReLU



Previsão de precipitação

Versão espacial: Lag=3



Hidden layers=[256, 128, 64]

Activation = ReLU

Perguntas e Perspectivas

- Entender o quanto podemos melhorar com a inclusão de dados espaciais.
- Qual o melhor intervalo de tempo para melhorar a predição?
- Implementar modelos de redes neurais convolucional.
- Implementar modelos LSTM.
- Procurar outras métricas para avaliar a eficiência dos modelos.

OBRIGADO!

Renan Oliveira Nunes

rj.renan@gmail.com

